

Orígenes evolutivos de familias génicas en parásitos kinetoplástidos

Introduccion

La historia de la vida está marcada por transiciones en diferentes momentos de la evolución entre formas de vida libres y parasitarias, cada transición es acompañada por profundas transformaciones genómicas y fenotípicas. Los parásitos representan una porción significativa de la biodiversidad eucariota, con su aparición se han generado cambios en la evolución y la ecología de prácticamente todos los demás organismos.

El parasitismo anteriormente se asociaba a una evolución reductiva, es decir pérdida génica, simplificación metabólica y dependencia del hospedador. Sin embargo, el parasitismo no implican únicamente pérdida de genes, sino también reorganización y expansión de ciertos genes. Al depender energéticamente del hospedador, los parásitos pueden enfrentar menos restricciones en cuanto al contenido genómico, lo que posibilita la retención y diversificación de familias génicas asociadas a la interacción hospedador-parásito.

Los Kinetoplástidos son un grupo de eucariotas que representan un buen modelo para estudiar estos procesos evolutivos, dado que incluye tanto organismos de vida libre (*Bodo saltans*, *Neobodo designs*) así como parásitos de gran relevancia médica (*Trypanosoma* y *Leishmania*) y agrícola (*Phytomonas*). Esta diversidad en un único grupo permite establecer comparaciones directas a nivel evolutivo sobre ganancia y pérdidas de genes.

Los genomas de *Trypanosoma brucei*, *Trypanosoma cruzi*, *Leishmania major* y *Phytomonas* tienen una organización genómica compleja, caracterizada por una alta proporción de familias génicas implicadas en la interacción con el hospedador, la evasión inmune y la adhesión celular. Entre las familias con mayor representación se encuentran trans-sialidasas, mucinas, MASP, amastinas y GP63, con distintos grados de divergencia entre e intra especies.

El origen evolutivo de estas familias genéticas asociadas al estilo de vida parasitario continúa siendo un tema en discusión. Una interrogante clave para entender los procesos evolutivos es determinar si estas familias génicas son innovaciones que surgieron junto con la transición hacia el parasitismo, o si derivan de genes de especies ancestrales preexistentes que posteriormente pudieron diversificarse y expandirse en respuesta a presiones selectivas ambientales como la interacción con el hospedador.

Para abordar esta pregunta se requiere un enfoque comparativo, en el cual se integre información genómica, filogenética y funcional, abarcando tanto parásitos como organismos de vida libre.

Objetivos

Objetivo general

Investigar los diferentes orígenes y la historia evolutiva de familias multigénicas en Kinetoplástidos parásitos, con el fin de identificar patrones de expansión, conservación y diversificación asociados al parasitismo a través de la evolución.

Objetivos específicos

Identificar las familias génicas conservadas en cada especie parasitaria y aquellas compartidas entre especies parásitas y de vida libre.

Reconstruir las relaciones evolutivas y los patrones de duplicación y pérdida de las familias génicas trans-sialidasas, mucinas, MASP, amastinas y GP63.

Analizar la organización genómica y la distribución cromosómica de dichas familias en cada especie.

Metodología

Obtención y preparación de datos genómicos

Los datos genómicos se obtendrán de la base de datos de Ensembl Protists (<https://protists.ensembl.org/>), seleccionando a las especies de Kinetoplastidos parásitos (*Trypanosoma cruzi*, *T. brucei*, *Leishmania major*) y de vida libre (como *Bodo saltans* y *Neobodo designis*), además se integraran genomas de Euglenozoa (*Euglena gracilis*, *Diplonema papillatum*, *Perkinsella spp.* y *Naegleria gruberi*) con el fin de abarcar la diversidad filogenética del grupo y de organismos ancestrales.

Desde el entorno online de Ensembl Protists se descargan los datos genómicos para cada especie, archivos formato FASTA (CDS y proteínas), archivos en formato GFF3 con las anotaciones y coordenadas. Además, archivos en formato FASTA del genoma completo.

Se aplicarán filtros en el buscador de Ensembl Protists para incluir únicamente genes anotados como “protein_coding” y excluir elementos hipotéticos o sin evidencia de transcripción.

Posteriormente, los datos se analizarán en un entorno local. Asimismo, se verificará que toda anotación y formatos se mantenga uniforme en las diferentes especies todo esto se hará a través de comandos de bash y comandos de awk. Las anotaciones se estandarizarán mediante scripts propios en R y Python, garantizando la compatibilidad entre especies y el correcto enlace entre las secuencias y sus metadatos (posición genómica, longitud, producto génico y tipo de anotación). Sobre todo normalizar las etiquetas de anotación que por lo general difieren en cambios mínimos pudiendo generar errores de análisis posteriores.

Identificación y clasificación de familias multigénicas

Dado que las anotaciones entre especies varían ya que son anotados en base a diferentes programas reanotaremos estas familias multigénicas a partir de un set de secuencias curadas de forma manual. Se realizará una búsqueda basándose en homología de secuencias mediante la herramienta BLAST con sus aplicaciones. Las secuencias identificadas serán agrupadas en familias génicas en base a criterios de similitud y se construirán perfiles de hmm a partir de los alineamientos para la búsqueda de homólogos remotos en especies ancestrales.

Análisis filogenético

Los alineamientos de cada familia se harán utilizando MAFFT, seguidos de la construcción filogenética mediante IQ-TREE con modelos de sustitución, seleccionando el mejor modelo que se ajuste. Se inferirán los patrones de duplicación y pérdida génica mediante superposición en un árbol de especies. Permitiendo identificar eventos de expansión o contracción asociados a la transición hacia el parasitismo.

Caracterización genómica y distribución cromosómica

Para los cálculos de longitud de secuencias, contenido de GC y frecuencias de dinucleótidos y trinucleótidos se realizarán en R utilizando el paquete seqinR. Este paquete permite manipular y analizar secuencias en formato FASTA de forma sencilla. Obteniendo para cada gen o familia un conjunto de características genómicas.

Las posiciones genómicas de cada familia se analizarán para evaluar su organización y distribución cromosómica, haciendo énfasis en la posible asociación de el entorno genómico, regiones subteloméricas y regiones centroméricas.

Estos resultados serán guardados en tablas que integrarán información de varias especies, familias génicas y características. Posteriormente, los valores obtenidos se someterán a análisis multivariantes, como el Análisis de Componentes Principales (PCA) haciendo uso de la herramienta scikit-learn de python, explorando patrones globales de estas características en cada una de las familias.

Aprendizaje automático

Se integrarán características genómicas, filogenéticas y estructurales de las familias multigénicas para realizar una clusterización basada en esta información. Los análisis se harán en Python, haciendo uso de la librería scikit-learn para aplicar métodos de reducción de dimensionalidad (PCA, t-SNE) y técnicas de clustering (k-means, DBSCAN). Permitirá identificar clusters entre familias que tengan características similares en las diferentes especies o las que no compartan ninguna de las características relevadas.

Desarrollo de un flujo de trabajo reproducible

Con el objetivo de asegurar la trazabilidad y reproducibilidad de los resultados, se implementará un pipeline automatizado en Nextflow, integrando todas las etapas del análisis (descarga de datos, filtrado, alineamiento, reconstrucción filogenética, cálculos genómicos y análisis multivariante). El código y los resultados intermedios serán versionados mediante Git y alojados en un repositorio GitHub público, siguiendo buenas prácticas de ciencia abierta y documentación transparente.

Visualización e integración de resultados

Los resultados se presentarán mediante representaciones gráficas y filogenéticas que integren la distribución evolutiva y genómica de las familias analizadas. Se espera obtener mapas filogenéticos que reflejen los patrones de expansión génica, la relación con regiones genómicas particulares y los posibles vínculos entre estructura y función. Finalmente, los datos integrados permitirán proponer hipótesis sobre el origen y diversificación de las familias multigénicas en los Kinetoplástidos, aportando un marco comparativo para comprender la evolución del parasitismo dentro del grupo.